




《人工智能综合设计》—信息检索的评测



人工智能综合设计 教研组



今日目标

- 实现自动评测所需函数：对给定的单个查询语句，返回检索前 20 的 url 列表
- 选择实现一个拓展功能



提纲



人工智能综合设计03 信息检索和倒排索引

- ☐ 信息检索评价
- ☐ 评测和打分说明
-
-



如何评价一个搜索引擎？

- 抓取和索引了多少个文档？
 - 待检索数据集越大越好
 - 每小时能抓取多少个网页？
 - 建立索引所用的时间？
- 搜索引擎的运行效率（efficiency）？
 - 用户的查询是否很快得到了响应？
 - 搜索引擎耗费了多少硬件资源？
- **最重要的评价对象：搜索引擎的运行效果（effectiveness）**
 - 搜索结果的质量
 - 搜索结果在多大程度上能满足用户的信息需求？
 - 用户获取信息所花的时间成本如何？



如何判断用户是否满意?

- 收集用户反馈
 - 正常使用搜索引擎的用户不会或很少给出反馈
- 用户点击搜索结果
 - 标题党的存在导致点击不一定可靠
- 用户行为
 - 用户是否修改查询
 - 用户是否很快离开
 - 用户是否在一定时间内回访
- 都需要与用户进行**在线交互**
 - **先上线系统，才能评价系统性能？**



间接估计用户满意度

- 由于直接获取用户满意度反馈十分困难
 - 反馈少/含义不明确/存在噪声
 - 需要线上系统
- 我们可以使用其他方式间接估计用户是否满意
- 最常用的方法：
 - 标注搜索结果的**相关性**(relevance)
 - 人工标注
 - 基于相关性标注计算不同**评价指标**



基于相关性标注的搜索评价

- 构建一个包含以下三部分数据测试集合：
 - 一个用于评价的**待检索文档集合**
 - 一个用于评价的**查询集合**
 - 可以认为是用户提交的查询的**采样**
 - **查询**和**待检索文档**之间的**相关性标注**：查询与文档**是否**相关
- 对于每个测试查询，可以基于相关性标注和搜索引擎返回结果计算**评价指标**
 - 集合/布尔检索：返回的搜索结果**集合**包含了多少**相关文档**
 - 排序检索：返回的搜索结果**列表**中**相关文档**的位置
- 用在查询集合上评价指标的平均值，评价搜索引擎的运行效果

相关性标注

- 最简单的情況可以进行二值标注：相关 或 不相关

查询：高瓴人工智能学院



不相关



相关

相关性标注

- 可以使用多级标注 (0, 1, 2, 3.....)
 - 0=>不相关; 分数越高越相关

查询：高瓴人工智能学院



0:不相关



1: 部分相关



2: 相关




相关性标注

- 潜在问题:
 - 假设待查询文档集合大小为5,000,000
 - 用于评测的查询个数为100
 - 标注每个查询与每个文档是否相关
 - $5,000,000 * 100 = 5 \times 10^8$
 - 假设每次相关性标注需要2s的时间
 - 10^9s
 - 大约需要31.69年

相关性标注

- 可以使用池过滤（pooling）的方法节约大量的标注
 - 一个没有被任何一个检索系统返回的文档对于**比较**系统的性能没有意义





相关性标注

- 可以使用池过滤（pooling）的方法节约大量的标注
 - 只需要标注被参与比较的搜索系统返回的文档即可
 - 使用100个测试查询，比较10个搜索系统，每个搜索系统返回20条结果
 - 标注数量 $\leq 100 \times 10 \times 20 = 20,000 \ll 5 \times 10^8$
- 如果使用该方法评价大家实现的搜索引擎
 - ~50位同学
 - ~100个测试查询
 - 考虑前20位结果
 - 标注数量： $50 \times 100 \times 20 = 100,000$
 - 5s标注一个结果需要138小时
 - 超出了助教的标注能力☹



评价指标计算

- 首先考虑：
 - 布尔检索：对于给定查询 检索 / 不检索 一个文档
 - 即检索到的集合是否包含某个文档
 - 二值的相关性标注：文档与查询 相关 / 不相关
- 类似于一个二分类问题
 - 模型输出：检索 / 不检索
 - 预测目标：相关 / 不相关
- 可以使用二分类的评价指标进行评价

评价指标计算

- 可以使用二分类的评价指标进行评价：
 - 准确率 (precision) : 检索到的文档中有多少比例是相关的
 - 召回率 (recall) : 有多少比例的相关文档被检索到了

	相关	不相关
检索	tp	fp
不检索	fn	tn

- Precision: $P = \frac{tp}{tp+fp}$
- Recall: $R = \frac{tp}{tp+fn}$



排序检索评价指标计算

- 考虑：
 - 排序检索： 每个文档会有一个在结果列表中的排序位置
 - 二值的相关性标注： 文档与查询 相关 / 不相关
- 评价指标：
 - Precision/Recall@K
 - MRR


排序检索评价指标计算

- 将排序检索转化为集合检索
 - 选定一个排序的阈值K
 - 检索排在前K位的结果，忽略剩下的排序结果
 - 计算Precision/Recall
- 一个只有一个查询的例子（绿色：相关）：
 - Precision@3: 2/3
 - Precision@4: 2/4
 - Precision@5: 3/5
 - Recall@3: 2/3
 - Recall@4: 2/3
 - Recall@5: 3/3



排序检索评价指标计算


- 通过不断改变K可以绘制Precision-recall曲线：
 - 曲线下面积越大，排序检索效果越好



排序检索评价指标计算

- 使用precision-recall曲线比较系统性能：
 - 给定系统S1和S2在一个查询下的检索结果（绿色：相关）

	1	2	3	4	5	6	7	8	9	10
S1	相关	相关	不相关	不相关	相关	不相关	相关	相关	不相关	不相关
S2	不相关	相关	相关	不相关	不相关	相关	不相关	不相关	相关	相关



排序检索评价指标计算

- 考虑用户是如何浏览搜索结果页面的，假设：
 - 用户从上往下一次浏览搜索结果
 - 找到第一个相关结果后结束浏览
 - 用户满意程度与其浏览结果付出的时间成本成反比
- MRR(Mean Reciprocal Rank , 平均首位相关结果倒数):

$$MRR = \frac{1}{|Q|} \sum_{i=1}^Q \frac{1}{\text{rank}_i}$$

- rank_i : 第 i 个测试查询中第一个相关结果的位置

排序检索评价指标计算

- MRR计算举例：
 - 三个测试查询：q1,q2,q3
 - 每个查询返回包含10个结果的排序

	1	2	3	4	5	6	7	8	9	10
q1										
q2										
q3										

– $MRR = 1/3 * (1/1 + 1/4 + 0) = 4/15$



排序检索评价指标计算

- 其他常见评价指标：
 - NDCG@N:
 - Normalized Discounted Cumulative Gain
 - 对结果进行多级相关性标注时适用
 - ERR: Expected Reciprocal Rank
 - Supported by Yahoo! and Google
 - 可以获取用户行为数据时适用
- 评价在信息检索系统的研发中一直处于核心的地位，以致于算法与其效果评价方式是合二为一的（Saracevic, SIGIR 1995）



提纲



人工智能综合设计03 信息检索和倒排索引

- ☐ 信息检索评价方法
- ☐ 评测和打分说明
-
-



爬虫范围

- <http://keyan.ruc.edu.cn/> 、 <http://xsc.ruc.edu.cn/>
- 所爬取的网站必须在上述域名下
- 如 hqjt.ruc.edu.cn 不符合要求



自动化评测

- 检测搜索引擎的检索能力
- 要求同学们实现如下函数：对给定的单个查询语句，返回检索前20 的 url 列表：

```
def evaluate(query:str) -> list:  
    # Your Program  
    url_list = [...]  
  
    assert len(url_list) == 20  
    return url_list
```




自动化评测

- 对每个查询词返回的 top 20 url 列表，计算平均 MRR
- 单次查询的 MRR 定义为，正确网页的 url 在 top 20 列表中出现的
位置的倒数
 - 正确网页可能不止一个，评测时使用首次出现的正确网页进行计算
- 如：[3 2 4 1 5]
- 如果 2 是正确答案， $MRR = \frac{1}{2}$
- 如果 1、5都是正确答案， $MRR = \frac{1}{4}$
- **08.31 会公布约 20 个查询，供大家进行调试**
- **09.03 进行最终测试，共约 100 个查询**
 - 除特殊情况外，每人只有一次测试打分机会



自动化评测

- 例子1:
- 数字孪生
- <http://keyan.ruc.edu.cn/wwsy/kydt/xsjl/ce85f5cad5514cc8af8fc229da924f1e.htm>



科研系统 | 登陆内网

输入搜索内容

首页

关于我们

科研项目

人大指数

科研奖项

科研机构

党群工作

学术交流

外网首页 科研动态 学术交流

青年创新汇客厅暨科研新势力座谈会举行 聚焦人工智能与国家治理现代化

发布时间: 2025. 07. 10

公共管理学院教授夏方舟阐述了人工智能在感知、决策、交互、模拟、协同五个方面的潜力，通过数据融合、决策赋能、**数字孪生**、政策模拟、云边协同等途径能够有效解决传统国土空间治理缺陷，促进决策智能跃升。



自动化评测

- 例子2:
- 智慧农业
- <http://xsc.ruc.edu.cn/info/1022/5291.htm>



新闻资讯

您当前所在的位置: 首页 -> 新闻资讯 -> 正文

先锋闯将企业行 | 人大师生代表赴腾讯参访

发布日期: 2025-04-24

主题交流

腾讯集团战略传播中心研究员、2006级校友赵罗希向同学们作“**AI技术的发展、应用与扩散**”主题介绍。他重点分析了当前中国AI技术和产业发展的现状与特色，介绍了腾讯元宝功能上的快速迭代和AI技术在质检、医疗、交通、农业等多个领域的应用实例，展示了腾讯在**智慧农业**、助老助残、环保节能、教育创新等方面的实践与探索。随后，同学们围绕“**未来AI与人类的关系**”等问题展开热烈讨论。



打分细则

- 自动化评测 (50 分)
 - 基于关键词的查询, 均为人工标注完成
- Web UI (5 分)
 - 接入助教给定的代码即可;
- 代码风格规范 (5 分)
 - 变量名命名风格、缩进、接口设计、不必要的全局变量 ...



打分细则

- 拓展功能（10 分）（**实现其一即可**）
 - 考虑idf的检索模型；
 - 考虑标题、锚文本等正文之外信息
 - Web UI 界面**优美**（比如好看、有摘要和关键词加亮等）
 - 其他扩展功能（需要在报告中说明实现的拓展功能）
 - 并行抓取、模拟翻页
 - 排序模型优化
- 实验报告及代码（20 分）
 - **按时**提交报告及代码至 obe；
 - **不要**提交倒排索引列表、爬取的网页、处理的中间结果等文件；
 - 报告不限字数，可包含模块设计、程序运行截图、核心代码展示、问题及解决思路等；
- 课堂展示（10 分，可选）
 - 项目亮点 / 核心代码展示 / 功能演示等；

谢谢!

